

AI_Olly_Custos - Guia Completo (Passo a passo + Códigos) - v2

Objetivo: colocar o projeto AI_Olly_Custos de p0 do zero, com repositório GitHub, Jobs no Databricks, ingestão de custos da Azure e **infraestrutura 100% automatizada com Terraform**.

=====

0) PRÉ-REQUISITOS

- Conta no Azure (assinatura ativa).
- Conta no GitHub.
- Um Workspace do Azure Databricks (ou deixe o Terraform criar opcionalmente).
- (Opcional local) Git + Python 3.11.

=====

1) SUBIR O CÓDIGO PARA O GITHUB

Opção GUI:

1. Baixe o pacote do projeto (ZIP) e descompacte.
2. GitHub -> New repository -> nome: AI_Olly_Custos -> Create.
3. Code -> Upload files -> suba as PASTAS/ARQUIVOS (branch main).

Opção Terminal:

```
git clone https://github.com/<org>/AI_Olly_Custos.git
cd AI_Olly_Custos
git add . && git commit -m "init: AI_Olly_Custos skeleton" && git push
```

=====

2) GITHUB SECRETS (AZURE + DATABRICKS)

2.1 AZURE_CREDENTIALS (Service Principal)

```
az login
az account set --subscription <SUBSCRIPTION_ID>
az ad sp create-for-rbac \
  --name "gh-ai-olly-custos" \
  --role contributor \
  --scopes /subscriptions/<SUBSCRIPTION_ID> \
  --sdk-auth
-> Copie o JSON de saída para o secret: AZURE_CREDENTIALS
```

2.2 DATABRICKS_HOST / DATABRICKS_TOKEN

- Launch Workspace (Azure Databricks) -> copie a URL (HOST)
- User Settings -> Developer -> Access tokens -> Generate (TOKEN)
- > Crie secrets: DATABRICKS_HOST e DATABRICKS_TOKEN

=====

3) GITHUB ACTIONS (PIPELINES)

- Faça um commit simples (README, por exemplo).
- Pipelines:
 - ci : checagens Python
 - deploy-databricks : cria/atualiza Repo/Job
 - deploy-infra : (se você mexer em infra/**) aplica Terraform
 - deploy-functions : publica a Azure Function (Timer)

=====

4) PRIMEIRO JOB (DATABRICKS)

- Workflows -> Jobs -> AI_Olly_Custos-train-daily -> Run now.
- Ver métricas em MLflow (execução).

=====

FASE 2 - DADOS REAIS (CUSTOS AZURE)

5) ADLS GEN2 (Storage) e permissões

- Crie Storage Account com Hierarchical namespace = Enabled.
- Conceda ao Service Principal: Storage Blob Data Reader (IAM).

6) COST MANAGEMENT EXPORT (diário -> ADLS)

- Cost Management -> Exports -> Add
 - Scope: Subscription | Recurrence: Daily | Format: CSV
 - Storage: o ADLS acima (container/pasta)
- Run now para gerar o primeiro CSV.

7) FUNCTION APP (timer) - opcional no início

- Function App (Linux, Python 3.11, plano Consumption).
- App Settings: COSTS_ACCOUNT_NAME, COSTS_CONTAINER, COSTS_PATH_PREFIX.
- O workflow deploy-functions publica o código do timer.

=====

FASE 3 - ALERTAS & PAINEL

- Log Analytics + KQL (exemplo):

```
AI_Olly_Custos_CL
| summarize avg(risk_score_d) by bin(TimeGenerated, 1d), scope_s
| order by TimeGenerated desc
```

- Azure Monitor Alerts (condição ex.: avg(risk_score_d) > 70).
- Grafana/Power BI lendo de Log Analytics/Storage.

=====

NOVIDADE - INFRAESTRUTURA AUTOMATIZADA (TERRAFORM)

Como aplicar (exemplo simples):

```
cd infra
terraform init
terraform apply -auto-approve -var="prefix=aiolly" -var="location=brazilsouth"
```

Opções:

```
-var="create_databricks=true"          # cria workspace Databricks
-var="create_cost_export=true"         # cria Export de Custos diário
-var="enable_function_diagnostics=true" # envia logs da Function para Log Analytics
```

Exemplo completo:

```
terraform apply -auto-approve \
  -var="prefix=aiolly" \
  -var="location=brazilsouth" \
  -var="create_databricks=true" \
  -var="create_cost_export=true" \
  -var="enable_function_diagnostics=true"
```

O que o Terraform cria:

- Resource Group
- Storage (ADLS Gen2) + container cost-exports
- Log Analytics + Application Insights (workspace-based)
- Service Plan (Linux Y1) + Function App (Python 3.11) com identidade gerenciada
- RBAC: Function -> Storage Blob Data Reader
- Diagnostic Settings do Storage -> Log Analytics
- (Opcional) Workspace Databricks
- (Opcional) Export de Custos diário para o ADLS

=====

CHECKLIST R`PIDO

- Actions "deploy-functions" falhando? Crie o Function App antes ou ajuste o nome.

- Sem dados? Verifique export, permissões IAM e caminho do container/prefixo.
- Databricks sem job? Confirme DATABRICKS_HOST/TOKEN e reexecute "deploy-databricks".

=====

ANEXO - ARQUIVOS DO PROJETO (CÓDIGOS COMPLETOS)

A seguir, o conteúdo dos principais arquivos.

===== ARQUIVO: README.md =====

(arquivo não encontrado)

===== ARQUIVO: .gitignore =====

(arquivo não encontrado)

===== ARQUIVO: requirements.txt =====

(arquivo não encontrado)

===== ARQUIVO: pyproject.toml =====

(arquivo não encontrado)

===== ARQUIVO: infra/providers.tf =====

```
terraform {
  required_version = ">= 1.6.0"
  required_providers {
    azurerm = {
      source = "hashicorp/azurerm"
      version = "~> 3.113"
    }
    random = {
      source = "hashicorp/random"
      version = "~> 3.6"
    }
  }
}

provider "azurerm" {
  features {}
}

data "azurerm_client_config" "current" {}
```

===== ARQUIVO: infra/variables.tf =====

```
variable "prefix" {
  description = "Prefixo curto para nomear recursos"
  type        = string
  default     = "aiolly"
}

variable "location" {
  description = "Região Azure"
  type        = string
  default     = "brazilsouth"
}

variable "tags" {
  description = "Tags padrão"
```

```

    type          = map(string)
    default = {
      project = "AI_Olly_Custos"
      owner   = "FinOps-SRE"
    }
  }
}

variable "create_databricks" {
  description = "Cria workspace Databricks (opcional)"
  type        = bool
  default     = false
}

variable "create_cost_export" {
  description = "Cria Export diário do Cost Management (requer permissies)"
  type        = bool
  default     = false
}

variable "enable_function_diagnostics" {
  description = "Ativa diagnósticos do Function App para Log Analytics"
  type        = bool
  default     = false
}

===== ARQUIVO: infra/resource_group.tf =====
resource "azurerm_resource_group" "rg" {
  name      = "${var.prefix}-rg"
  location  = var.location
  tags      = var.tags
}

===== ARQUIVO: infra/storage.tf =====
resource "random_string" "suf" {
  length  = 5
  upper   = false
  lower   = true
  number  = true
  special = false
}

resource "azurerm_storage_account" "sa" {
  name                                = "${replace(var.prefix, "-", "", "")}${random_string.suf.result}sa"
  resource_group_name                 = azurerm_resource_group.rg.name
  location                           = azurerm_resource_group.rg.location
  account_tier                       = "Standard"
  account_replication_type           = "LRS"
  min_tls_version                    = "TLS1_2"
  allow_blob_public_access           = false
  enable_https_traffic_only          = true
  is_hns_enabled                     = true # ADLS Gen2
  tags                               = var.tags
}

resource "azurerm_storage_container" "cost" {

```

```

name                = "cost-exports"
storage_account_name = azurerm_storage_account.sa.name
container_access_type = "private"
}

```

===== ARQUIVO: infra/log_analytics.tf =====

```

resource "azurerm_log_analytics_workspace" "law" {
  name                = "${var.prefix}-law"
  location            = azurerm_resource_group.rg.location
  resource_group_name = azurerm_resource_group.rg.name
  sku                 = "PerGB2018"
  retention_in_days   = 30
  tags                = var.tags
}

```

```

resource "azurerm_application_insights" "appi" {
  name                = "${var.prefix}-appi"
  location            = azurerm_resource_group.rg.location
  resource_group_name = azurerm_resource_group.rg.name
  application_type     = "web"
  workspace_id        = azurerm_log_analytics_workspace.law.id
  tags                = var.tags
}

```

===== ARQUIVO: infra/function.tf =====

```

resource "azurerm_service_plan" "plan" {
  name                = "${var.prefix}-plan"
  location            = azurerm_resource_group.rg.location
  resource_group_name = azurerm_resource_group.rg.name
  os_type             = "Linux"
  sku_name            = "Y1" # Consumption
  tags                = var.tags
}

```

```

resource "azurerm_linux_function_app" "func" {
  name                = "${var.prefix}-func"
  location            = azurerm_resource_group.rg.location
  resource_group_name = azurerm_resource_group.rg.name
  service_plan_id     = azurerm_service_plan.plan.id
}

```

Armazenamento para contextos/funcionamento

```

storage_account_name      = azurerm_storage_account.sa.name
storage_account_access_key = azurerm_storage_account.sa.primary_access_key

```

```

functions_extension_version = "~4"

```

```

identity {
  type = "SystemAssigned"
}

```

```

site_config {
  application_stack {
    python_version = "3.11"
  }
  ftps_state = "Disabled"
}

```

```

app_settings = {
  "WEBSITE_RUN_FROM_PACKAGE"      = "1"
  "APPINSIGHTS_INSTRUMENTATIONKEY" =
    azurerm_application_insights.appi.instrumentation_key
  "APPLICATIONINSIGHTS_CONNECTION_STRING" =
    azurerm_application_insights.appi.connection_string

  # Ajuste conforme sua leitura de custos
  "COSTS_ACCOUNT_NAME" = azurerm_storage_account.sa.name
  "COSTS_CONTAINER"    = azurerm_storage_container.cost.name
  "COSTS_PATH_PREFIX"  = "exports/"
}

tags = var.tags
}

# Permissão para a Function ler blobs do Storage
resource "azurerm_role_assignment" "func_blob_reader" {
  scope                = azurerm_storage_account.sa.id
  role_definition_name = "Storage Blob Data Reader"
  principal_id         = azurerm_linux_function_app.func.identity[0].principal_id
}

===== ARQUIVO: infra/diagnostics.tf =====
# Logs do Storage -> Log Analytics (@til para auditoria/monitoramento)
resource "azurerm_monitor_diagnostic_setting" "sa_to_law" {
  name                = "${var.prefix}-sa-diag"
  target_resource_id  = azurerm_storage_account.sa.id
  log_analytics_workspace_id = azurerm_log_analytics_workspace.law.id

  enabled_log {
    category = "StorageRead"
  }
  enabled_log {
    category = "StorageWrite"
  }
  enabled_log {
    category = "StorageDelete"
  }

  metric {
    category = "AllMetrics"
    enabled  = true
  }
}

# (Opcional) Logs da Function App -> Log Analytics (algumas categorias podem variar;
# deixe desativado se não tiver certeza)
resource "azurerm_monitor_diagnostic_setting" "func_to_law" {
  count                = var.enable_function_diagnostics ? 1 : 0
  name                = "${var.prefix}-func-diag"
  target_resource_id  = azurerm_linux_function_app.func.id
  log_analytics_workspace_id = azurerm_log_analytics_workspace.law.id

  enabled_log {
    category = "FunctionAppLogs"
  }
}

```

```

    }
    metric {
      category = "AllMetrics"
      enabled  = true
    }
  }
}

```

===== ARQUIVO: infra/cost_export.tf =====

```

# Export diário do Azure Cost Management para o ADLS (opcional)
# ATENÇÃO: requer permissões específicas na assinatura para criar exports.
# Habilite com -var="create_cost_export=true"
resource "azurerm_cost_management_export" "daily" {
  count = var.create_cost_export ? 1 : 0

  name = "${var.prefix}-cost-export"
  scope = "/subscriptions/${data.azurerm_client_config.current.subscription_id}"

  recurrence = "Daily"

  recurrence_period {
    from = "2025-09-01T00:00:00Z"
    to   = "2030-01-01T00:00:00Z"
  }

  delivery_info {
    destination {
      resource_id      = azurerm_storage_account.sa.id
      container        = azurerm_storage_container.cost.name
      root_folder_path = "exports"
    }
  }

  format = "Csv"
  time_period {
    type = "BillingMonthToDate"
  }
}

```

===== ARQUIVO: infra/databricks.tf =====

```

# Criação opcional de um workspace Databricks (muitos ambientes já possuem um)
resource "azurerm_databricks_workspace" "dbw" {
  count          = var.create_databricks ? 1 : 0
  name           = "${var.prefix}-dbw"
  resource_group_name = azurerm_resource_group.rg.name
  location       = azurerm_resource_group.rg.location
  sku            = "premium"
  tags           = var.tags
}

output "databricks_workspace_url" {
  value          = try(azurerm_databricks_workspace.dbw[0].workspace_url, null)
  description    = "URL do workspace Databricks (se criado)"
}

```

===== ARQUIVO: infra/outputs.tf =====

```

output "resource_group" {
  value = azurem_resource_group.rg.name
}

output "storage_account_name" {
  value = azurem_storage_account.sa.name
}

output "storage_container_cost_exports" {
  value = azurem_storage_container.cost.name
}

output "function_app_name" {
  value = azurem_linux_function_app.func.name
}

output "log_analytics_workspace_id" {
  value = azurem_log_analytics_workspace.law.id
}

output "application_insights_connection_string" {
  value = azurem_application_insights.appi.connection_string
}

```

```

===== ARQUIVO: infra/README_INFRA.md =====
# Infraestrutura - AI_Olly_Custos (Terraform)

```

```

## O que este IaC cria
- Resource Group
- Storage Account (ADLS Gen2) + Container 'cost-exports'
- Log Analytics Workspace + Application Insights (workspace-based)
- Service Plan (Linux, Consumption) + Function App (Python 3.11) com identidade
  gerenciada
- RBAC: Function -> Storage Blob Data Reader
- Diagnósticos do Storage para Log Analytics
- (Opcional) Workspace Databricks
- (Opcional) Export Diário do Cost Management para o ADLS

```

```

## Como aplicar
```bash
cd infra
terraform init
terraform apply -auto-approve
```

```

```

### Opções extras
- Criar Databricks: `--var="create_databricks=true"`
- Criar Export de Custos: `--var="create_cost_export=true"`
- Ativar diagnostics da Function: `--var="enable_function_diagnostics=true"`

```

Exemplo completo:

```

```bash
terraform apply -auto-approve -var="prefix=aiolly"
-var="location=brazilsouth" -var="create_cost_export=true"
-var="enable_function_diagnostics=true"
```

```


> Dica: o workflow GitHub Actions ``.github/workflows/deploy-infra.yml`` já roda ``terraform init/validate/apply`` automaticamente ao modificar arquivos em ``infra/**``.

===== ARQUIVO: jobs/train_job.json =====
(arquivo não encontrado)

===== ARQUIVO: notebooks/train_forecast.py =====
(arquivo não encontrado)

===== ARQUIVO: src/ai_olly_custos/__init__.py =====
(arquivo não encontrado)

===== ARQUIVO: src/ai_olly_custos/pipeline.py =====
(arquivo não encontrado)

===== ARQUIVO: src/ai_olly_custos/scoring_function/__init__.py =====
(arquivo não encontrado)

===== ARQUIVO: src/ai_olly_custos/scoring_function/function.json =====
(arquivo não encontrado)

===== ARQUIVO: .github/workflows/ci.yml =====
(arquivo não encontrado)

===== ARQUIVO: .github/workflows/deploy-infra.yml =====
(arquivo não encontrado)

===== ARQUIVO: .github/workflows/deploy-databricks.yml =====
(arquivo não encontrado)

===== ARQUIVO: .github/workflows/deploy-functions.yml =====
(arquivo não encontrado)